attack-on-scada

December 13, 2023

DETEKCIJA NAPADA U OKVIRU SCADA SISTEMA

U okviru nastavka ovog dokumenta prolazicemo kroz samu analizu rada sistema kao i kroz samu detekciju napada.

Navigacija

- Packages
- Dataset
- Rad Sistema
- Decision tree
- Random forest algorithm
- Random forest u praksi

Packages

Neke od danasnjih najpopularnijih biblioteka su koriscene i prilikom ovog istrazivanja.

pandas Veoma efikasno rukovanje csv fajlovima

matplotlib Vizuelizacija podataka

XGBoost Extreme Gradient Boosting

Numpy Pogodan za efikasnan rad sa nizovima podataka

SCKIT-LEARN Open source library za machine learning

[5]:
```
import pandas as pd
import xgboost as xgb
import matplotlib.pyplot as plt
from radSistema import *
from IPython.display import Image
import numpy as np
import sklearn
```

Dataset

U okviru ovog dela dokumenta izvrsicemo samo upoznavanje sa nasim podacima.

[3]:
```
pdDf = pd.read_csv('learningDataNew.csv')
pd.set_option('expand_frame_repr', False)
print(f"Broj vrsta u okviru naseg dataset-a je:{pdDf.shape[0]}.")
print(f"Broj kolona u okviru naseg dataset-a je:{pdDf.shape[1]}.")
```

```
print(pdDf.head())
```

```
Broj vrsta u okviru naseg dataset-a je:239.
Broj kolona u okviru naseg dataset-a je:9.
   WT_VALUE01  WT_VALUE02  WT_VALUE03  CR_VALUE01  CR_VALUE02  CR_VALUE03
REPLAY_ATTACK  COMMAND_INJECTION  NORMAL_STATE
0          248          253          259           0           0           0
0                   0             1
1          230          226          223           1           0           0
0                   0             1
2          220          220          221           0           0           0
0                   0             1
3          226          230          235           0           0           0
0                   0             1
4          247          253          259           0           0           0
0                   0             1
```

Svaka kolona predstavlja nesto specificno u okviru dataset-a,tako je WT skarenica za Water Thermometer,dok je CR skracenica za Control Rods. Iz samog zaglavlja mozemo zakljuciti da smo belezili 3 uzastopne vrednosti WT kao i CR i nakon toga belezili da li su te vrednosti zabelezene u diskretnom trenutku prilikom normalnog rada sistema ili nekog napada. Ukoliko je u okviru kolone NORMAL_STATE upisana jedinica znaci da je sekvenca od 3 podatka zabelezena kada je sistem bio u normalnom stanju rada bez smetnji. Iz ovoga zakljucujemo da ukoliko su jedinice upisane u okviru kolona gde se nalaze REPLAY_ATTACK i COMMAND_INJECTION sekvenca podataka je bila zabelezena prilikom tih napada. Zaglavlje:

[4]:
```
zaglavlje = ""
zaglavlje += " ".join(pdDf.head(0).columns)
# Print the result
print(zaglavlje)
```

```
WT_VALUE01 WT_VALUE02 WT_VALUE03 CR_VALUE01 CR_VALUE02 CR_VALUE03 REPLAY_ATTACK
COMMAND_INJECTION NORMAL_STATE
```

Rad sistema

U nastavku ce biti prikazan dijagram rada sistema u sva 3 slucaja. U okviru ovoga smo posmatrali samo Wather Thermometer koji moze da nam indikuje na to da su dosle neke nepravilnosti posto on sam predstavlja analognu vrednostdok su Control Rods diskretna vrednost 1 ili 0 u zavisnosti da li su spusteni(1) ili nisu spusteni(0). Za svrhu prikazivanja rada sistema koristicemo pomocnu f-ju koja se nalazi u radSistema.py

Normalan rad sistema

[5]:
```
makePairsForPlot(pdDf)
```

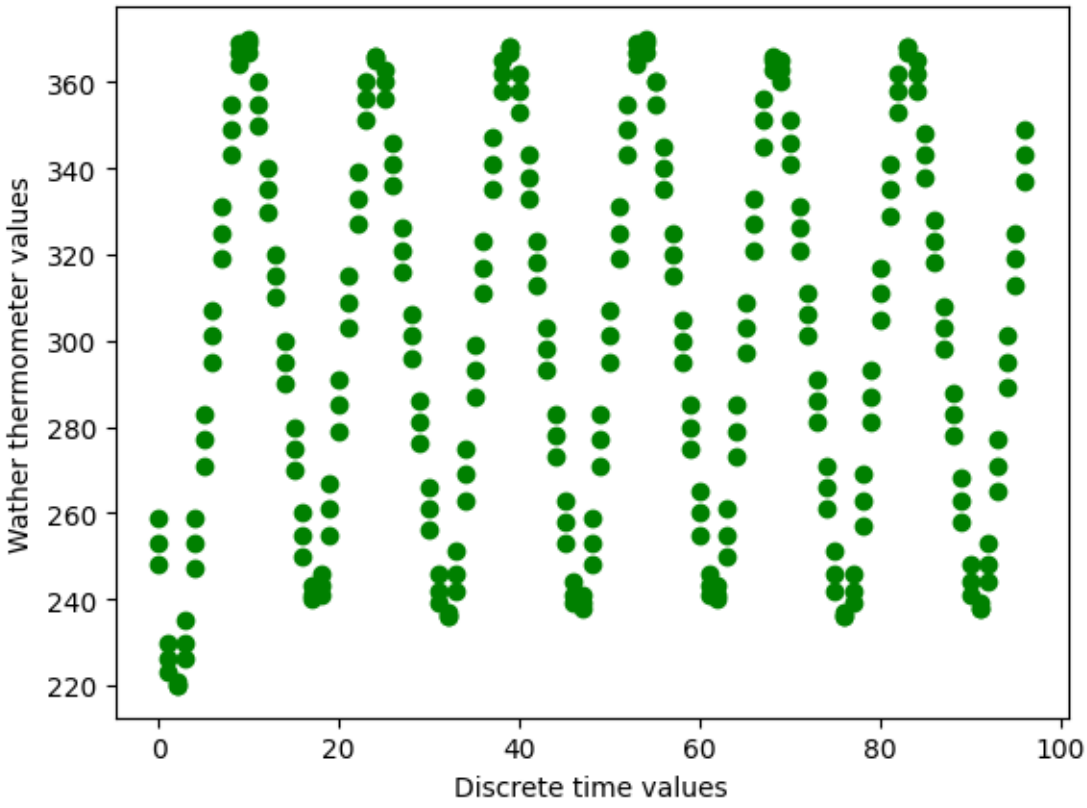

Rad sistema prilikom replay attack-a

[6]:
```
makePairsForPlot(pdDf,state="REPLAY_ATTACK",dot_color="red")
```

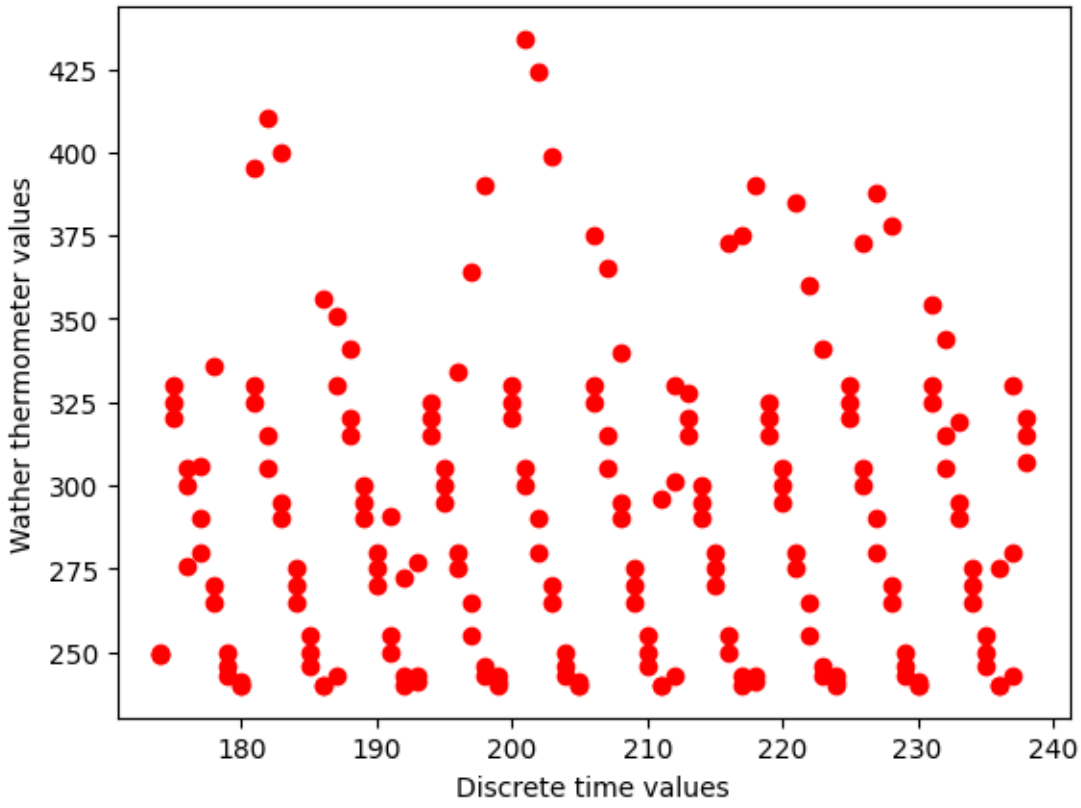

Rad sistema prilikom command injectiona

[7]:
```
makePairsForPlot(pdDf,state="COMMAND_INJECTION",dot_color="darkred")
```

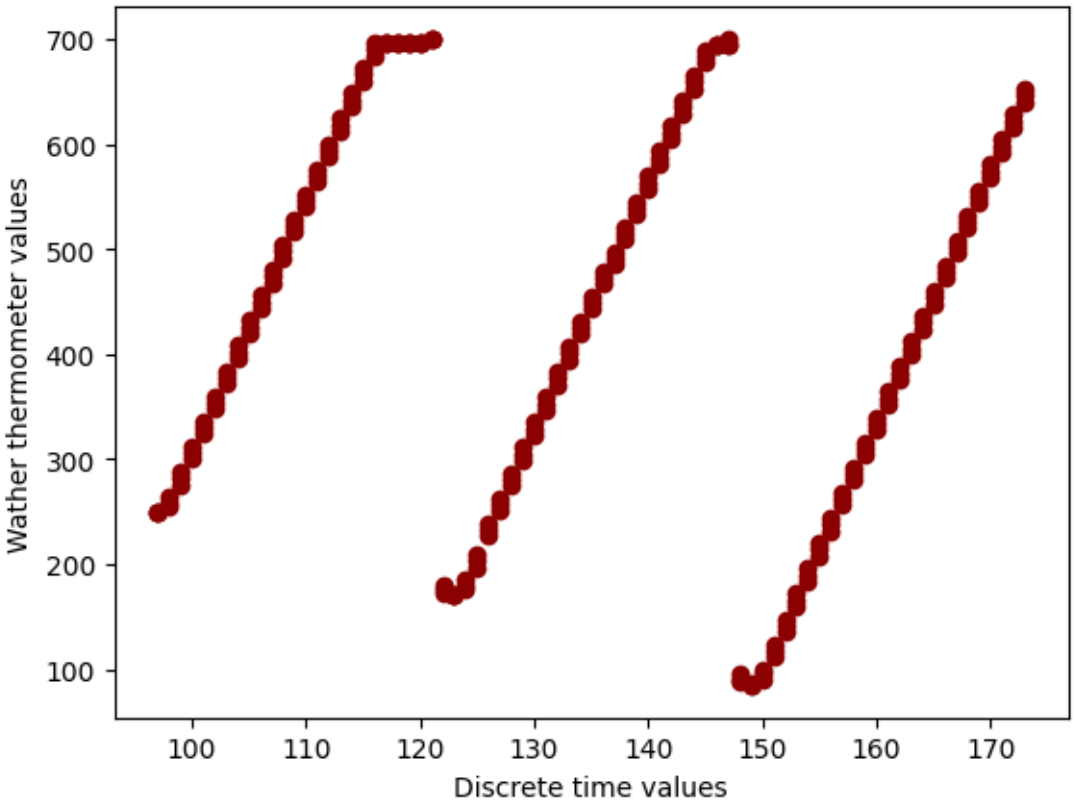

Decision tree

U okviru ovog dela dokumenta cemo se upoznati sa samom logikom rada decision tree-a posto je sama implementacija banalna,medjutim da ne bi koristili machine learning modele kao black box modele dobro je znati sta se to zapravo odvija u pozadini i kakve nam sve mogucnosti daje.

Measuring purity

Decision tree koristi f-ju entropije kako bi izmerio “cistocu” odnosno “necistocu” dataset-a na sta se to odnosi videcemo u dole konkretnim primerima.

[2]:
```
image_path = 'entropy.png'
display(Image(filename=image_path))
```

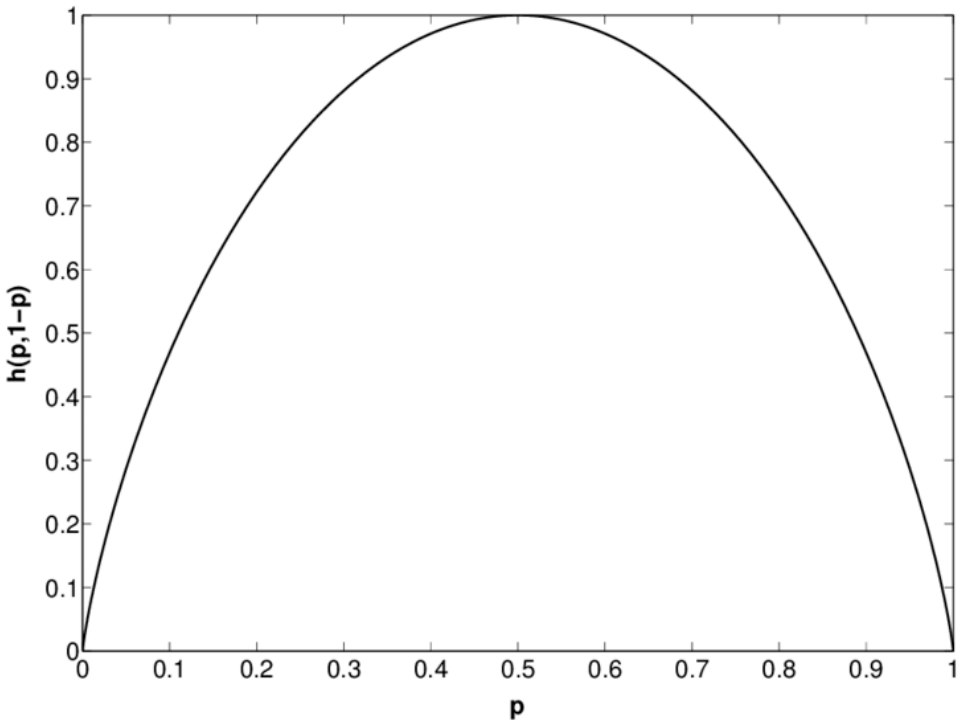

Sa same slike ne mozemo nista posebno da zakljucimo dok ne uvedemo konkretne primere. Najvaznije je napomenuti da kada nam je p = 0.5 “necistoca” dataset-a maksimalna == 1 p = 0 => “necistoca” dataset-a == 0 p = 1 => “necistoca” dataset-a == 0

[6]:
```
image_path01 = 'example01.png'
print("Primer 1:")
display(Image(filename=image_path01))
```

```
Primer 1:
```

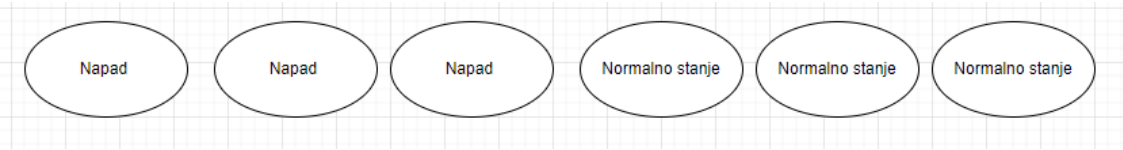

Posmatrajmo primer iznad gde vidimo da imamo 3 podatka koji su napadi isto tako 3 podatka koji su normalno stanje. Mi merimo necistocu dataset-a po tome koliko imamo napada,dakle u nasem slucaju p ce predstavljati deo primeraka koji su upravo napadi => p = 3/6 Iz ovoga ako pogledamo sliku mozemo da zakljucimo da nam je “necistoca” dataset-a maksimalna == 1.

[7]:
```
image_path02 = 'example02.png'
print("Primer 2:")
display(Image(filename=image_path02))
```

```
Primer 2:
```

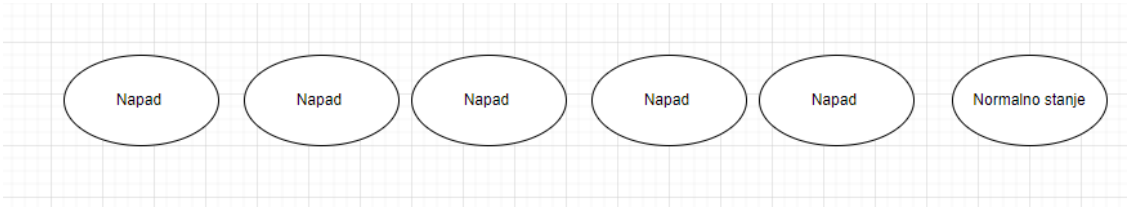

U primeru broj 2 mozemo da vidimo da imamo 5 napada => p = 5/6 => “necistoca” dataset-a 0.65

Ovo nam je vrlo vazno da znamo posto samo splitovanje podataka koje ce nas decision tree odraditi u pozadini se zasniva na ovom konceptu koji ce biti prikazan na slici ispod.

[8]:
```
image_path03 = 'example03.png'
print("Primer 3:")
display(Image(filename=image_path03))
```

```
Primer 3:
```

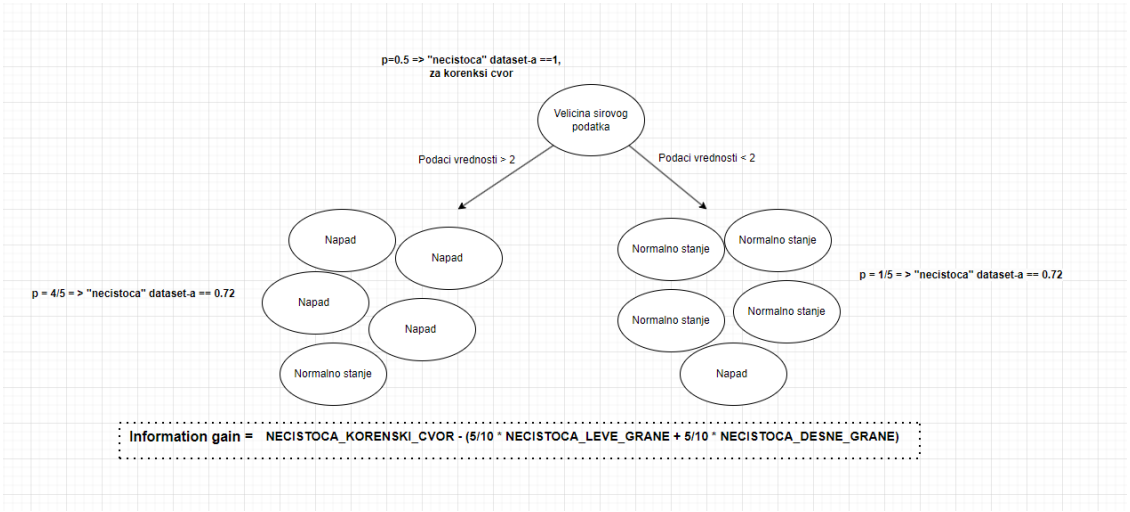

Na slici iznad vidimo jedan prost korak splitovanja podatak koji iskarikiran,sto bi znacilo da ne mora da znaci da nas model vrsi ovakvo splitovanje. Na primeru sa slike mi zelimo da dodjemo do rezonovanja sta je napad on nasih podataka. U okviru korenskog cvora necistoca je uvek 1 tj p za root je uvek ==0.5 Splitovanje smo vrsili tako sto smo gledali velicinu podatka dakle ako je nas podatak > 2 on bi zavrsio u levom delu stabla u suprotnom bi zavrsio u desno. Nakon ovoga

ponavljamo postupak za levi i desni deo stabla. Kada smo odradili ovaj postupak za levi i desni deo racunamo INFORMATION GAIN on nam je jako bitan zato sto na osnovu njega znamo da li ima svrhe da se nase stablo prosiruje i da vrsi dalje splitovanje tih podataka. Ako bi on bio mali reda 0.03 sto cemo videti u sledecem primeru koji nije vezan za konkretno ovaj problem mi nemamo razloga da dalje vrsimo splitovanje podataka i tu se zaustavljamo. Kada bi ubacili ove nase vrednosti dobili bi smo 0.28 sto bi znacilo da imamo razloga da dalje splitujemo. Koeficient 5/10 ili ti 0.5 koji stoji uz "necistocu" leve i desne grane je dobijen tako sto smo videli koliko je podataka od samog korenskog cvora zavrsilo u levom a koliko u desnom delu.

[10]:
```
image_path04 = 'example04.png'
print("Primer 4:")
display(Image(filename=image_path04))
```

```
Primer 4:
```

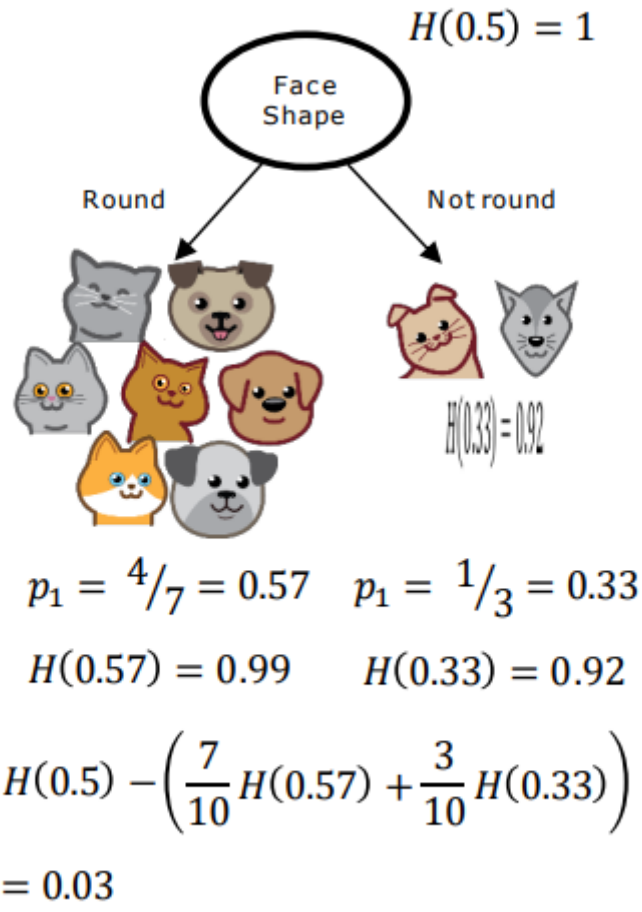

Do kada ponavljamo ovaj proces?

Dok ne dodjemo do toga da je jedan cvor 100% jedna klasa.

Ako smo trenutnim splitovanjem dosli do maksimalne dubine stabla.

Ako je information gain manji od thresholda

Ako je broj podataka manji od thresholda

Radom forest algorithm

Sam decision tree kao tehnika masinskog ucenja je veoma mocna ali njegovo prosirenje omogucava mnogo bolje nacine da vrsimo predvidjanja. U kombinaciji sa XGBoost-om nam daje veoma dobar algoritam koji dosta brze zakljucuje u odnosu na neuronsku mrezu,naravno kada govorimo o struktuiranim podacima. Mreza se dosta bolje ponasa prilikom obrade i zakljucivanja kod podataka koji nisu struktuirani kao sto su slike,audio,video...

Pseudokod Imamo dataset na pocetku od kog cemo da formiramo decision tree. for b=1 to B: U okviru petlje se korisisti sample and replacement proces kako bi se kreiralo novo stablo B - predstavlja broj decision tree-a koji zelimo da napravimo Sample and replacement - U svakoj iteraciji se vrsi formiranje novog decision tree-a. Ovaj proces mozemo da zamislimo kao da smo sve nase podatke stavili u jedan veliki dzak i u svakoj iteraciji prilikom kreiranja novog stabla vrsimo vadjenje odredjenog broja podataka kako bi formirali stablo sa tim sto kada neki podatak iskoristimo u formiranju nekog stabla u odredjenoj iteraciji taj podatak dobija odredjenu tezinu(weight) kako bi i drugi podaci dobili prednost prilikom formiranja sledeceg stabla. Svakako postoji mogucnost da se neki podatak nadje u nekom stablu 2 puta. Jos jedna od brojnih prednosti XGBoost-a je ta sto od vise kreiranih stabala mozemo da kreiramo novo stablo tako sto spajamo prethodna i tako dolazimo do potencijalno najbolje predikcije.

Random forest u praksi

U okviru ovog dela dokumenta procicemo kroz samo koriscenje xgboost-a. Prvo sto treba da uradimo je da ucitamo podatke na kojima cemo trenirati nas tree.

[9]:
```
boost = np.loadtxt("learningDataNew.csv",delimiter=',',skiprows=1) #preskacemo␣
 ↪prvu vrstu zato sto nam je to header



X = boost[: , 0:6] #prvih 6 kolona su nam zapravo input
Y = boost[: , 6:9] #poslednje 3 kolone su targeti

X_train, X_test, y_train, y_test = sklearn.model_selection.
 ↪train_test_split(X,Y,test_size=0.35,random_state=39)

model = xgb.XGBClassifier(random_state=42, max_depth=9, tree_method="hist",␣
 ↪multi_strategy="multi_output_tree",n_estimators=100,nthread=5,learning_rate=0.
 ↪32)
print(model)
```

```
XGBClassifier(base_score=None, booster=None, callbacks=None,
              colsample_bylevel=None, colsample_bynode=None,
              colsample_bytree=None, device=None, early_stopping_rounds=None,
              enable_categorical=False, eval_metric=None, feature_types=None,
              gamma=None, grow_policy=None, importance_type=None,
```

```
interaction_constraints=None, learning_rate=0.32, max_bin=None,
max_cat_threshold=None, max_cat_to_onehot=None,
max_delta_step=None, max_depth=9, max_leaves=None,
min_child_weight=None, missing=nan, monotone_constraints=None,
multi_strategy='multi_output_tree', n_estimators=100, n_jobs=None,
nthread=5, num_parallel_tree=None, …)
```

TRAIN_TEST_SPLIT

Velicina testnog skupa je preporucljiva da bude izmedju 0.2-0.35,ako bi testni skup bio previse mali model bi se na oko cinio dobar(npr test_size=0.1), ali kada bi dobio nove podatke skroz bi se izgubio(ne bi znao model dobro da prediktuje). random_state -Definise nacin na koji ce se vrsiti podela samog dataset-a ako nismo definisali uvek ce drugacija podela biti izvrsena,dok ako stavimo neki celobrojni podatak uvek ce se vrsiti ista podela. Eksperimentalno prilikom razvoja modela 39 se pokazala kao najbolja odluka.

Kreiranje modela

Random state-radi na slicnom principu kao i kod train test splita samo se ne formira skup za treniranje nego decions trees,isto je ekesperimentalno utvrdjeno da je 42 najbolja opcija. MAX_DEPTH -definse maksimalnu dubinu stabla kako bi se sprecio overfiting,ako mi ne definisemo po defaultu je max_depth = 10 Eksperimentalno dosli smo do zakljucka da dubina 9 daje najbolji model 84+ % tacnosti,dok dubina 6 daje 82+ %. Postavlja se pitanje da li uzeti vece stablo sa vecom tacnoscu ili je ipak bolje uzeti manje stablo gde brze dolazimo do odluke. Odgovor lezi u tome da u sistemima koji su uceni na vecoj kolicini podataka 2% nam ne znace preterano ako dolazimo brze do odluke. Za nas sistem smo koristili vece stablo posto je sistem ucen na maloj kolicini podataka i svakako nam model dosta brzo odlucuje,jednostavno smo hteli vecu preciznost. TREE_METHOD -Sa ovim definisemo nacin optimizacije formiranja novih stabala. Kada smo ovom parametru dodeli hist on ce koristiti greedy algorithm kako bi brze formirao nova stabla na osnovu istorije vec kreiranih. MULTI_STRATEGY -Ovaj parametar se koristi u kombinaciji sa three_method=“hist” (preporuceno je) Govori da ce broj listova biti jedna sa brojem outputa koji treba da se prediktuje. N_ESTIMATORS -Zapravo govori koliko ce biti B iz pseudokoda.Eksperimentalno se 100 pokazalo kao najbolje. NTHREAD -Koliko ce tredova da vrsi tu obradu.Eksperimentalno se 5 pokazalo kao najbolje. LEARNING_RATE -Koliko ce brzo da uci model posto ipak sam naziv je EXTREME GRADIENT BOOST(skracenica od xgboost).Eksperimentalno se 0.32 pokazalo kao najbolje.

[12]:
```
model.fit(X_train,y_train) #treniranje modela
pred = model.predict(X_test) #predikcija nad testnim podacima
print(pred)
```

```
[[0. 1. 0.]
 [0. 0. 1.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 0. 1.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [0. 0. 1.]
 [0. 1. 0.]
```

```
[0. 0. 1.]
[1. 0. 1.]
[1. 0. 0.]
[0. 0. 1.]
[1. 0. 0.]
[0. 0. 1.]
[1. 0. 0.]
[1. 0. 0.]
[0. 1. 0.]
[0. 0. 1.]
[0. 0. 1.]
[0. 0. 1.]
[0. 0. 1.]
[0. 0. 1.]
[0. 1. 0.]
[0. 1. 0.]
[1. 0. 0.]
[0. 0. 1.]
[0. 1. 0.]
[0. 1. 0.]
[0. 1. 0.]
[0. 0. 1.]
[0. 0. 1.]
[0. 1. 0.]
[0. 0. 1.]
[1. 0. 0.]
[0. 0. 1.]
[1. 0. 0.]
[0. 0. 1.]
[0. 0. 1.]
[0. 1. 0.]
[0. 1. 0.]
[0. 1. 0.]
[1. 0. 0.]
[0. 0. 0.]
[0. 0. 1.]
[0. 1. 0.]
[1. 0. 0.]
[0. 0. 1.]
[0. 1. 0.]
[0. 0. 1.]
[0. 0. 1.]
[0. 1. 0.]
[1. 0. 0.]
[0. 0. 1.]
[0. 1. 0.]
[0. 1. 0.]
[0. 0. 1.]
```

```
 [0. 1. 0.]
 [1. 0. 0.]
 [0. 0. 1.]
 [0. 0. 1.]
 [0. 0. 1.]
 [0. 0. 1.]
 [1. 0. 1.]
 [0. 0. 1.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 0. 1.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 0. 1.]
 [1. 0. 0.]
 [0. 1. 0.]
 [1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 1. 0.]
 [0. 0. 1.]
 [0. 1. 0.]
 [1. 0. 0.]
 [0. 0. 1.]]
```

[15]:
```
acc = sklearn.metrics.accuracy_score(y_test, pred) #racunanje preciznosti modela
print("Acc: %.2f%%" % (acc * 100.0))
print(f'Mean squared error:{sklearn.metrics.mean_squared_error(y_test, pred)}')
```

```
Acc: 84.52%
Mean squared error:0.09126984126984128
```

Kako ne bi svaki put vrsili ponovno treniranje ovako natreniran model sacuvacemo i kasnije samo ucitati za upotrebu.

[16]:
```
model.save_model('xgbNew.json')
```

[18]:
```
newModel = xgb.XGBClassifier()
newModel.load_model('xgbNew.json')
print(newModel)
```

```
XGBClassifier(base_score=None, booster=None, callbacks=None,
              colsample_bylevel=None, colsample_bynode=None,
              colsample_bytree=None, device=None, early_stopping_rounds=None,
              enable_categorical=False, eval_metric=None, feature_types=None,
              gamma=None, grow_policy=None, importance_type=None,
```

```
                interaction_constraints=None, learning_rate=None, max_bin=None,
                max_cat_threshold=None, max_cat_to_onehot=None,
                max_delta_step=None, max_depth=None, max_leaves=None,
                min_child_weight=None, missing=nan, monotone_constraints=None,
                multi_strategy=None, n_estimators=None, n_jobs=None,
                num_parallel_tree=None, random_state=None, …)
```

[22]:
```
y_pred1 = model.predict(X_test)
y_pred2 = newModel.predict(X_test)

models_equal = (y_pred1 == y_pred2).all()

if models_equal:
    print("The predictions of Model 1 and Model 2 are equal.")
```

```
The predictions of Model 1 and Model 2 are equal.
```

Iz ovoga dolazimo do zakljucka da imamo 2 ista modela.